



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
PROFESOR: DENIS PARRA
IIC3633- SISTEMAS RECOMENDADORES
SEGUNDO SEMESTRE - 2024

Propuesta proyecto

Alumno: Gustavo Cornejo Olea - Juanita Fernández - Fransisco Jorquera

1. Descripción y justificación del problema a tratar

El presente proyecto se desarrolla dentro del contexto de juegos de cartas coleccionables (CCG) y en particular en el caso del juego Hearthstone. Hearthstone es un juego *online* y *free-to-play* de la compañía Blizzard Inc. que para 2016 ya había alcanzado el total de 40 millones de cuentas registradas y que consiste en partidas entre dos jugadores, donde cada uno tendrá un mazo de 30 cartas y 30 puntos de vida (la naturaleza de las mismas será descrita más adelante) y, por turnos, avanzarán durante la partida manejando sus cartas con el fin de atacar al contrincante hasta acabar sus puntos de vida.

A lo largo de este proyecto buscaremos implementar sistemas recomendadores que entreguen al usuario un mazo que pueda tener un buen desempeño en las partidas del juego. El proyecto buscará replicar el análisis realizado por Chen y Amato [Chen et al.2018] junto con implementar sistemas propios.

La justificación de este proyecto viene de la cantidad de cartas y variables a considerar dentro del mazo. Es importante considerar que cada jugador elige un personaje jugable que tendrá su propia dinámica o “poder de héroe” (dinámica que puede consistir en jugar una determinada carta o aumentar puntos de salud) y tendrán que armar un mazo con cartas compatibles con su personaje, de un total de más de 5000 cartas, las cuales se dividen en aliados y hechizos. Los aliados son personajes que se mantienen a lo largo de la partida y permiten atacar al adversario o a los aliados del mismo, mientras los hechizos tienen diversos efectos en la partida, pero desaparecen automáticamente.

Naturalmente al encontrar una forma eficiente de armar un mazo se logra beneficiar tanto a usuarios como a los desarrolladores. Los desarrolladores se benefician al tener maneras eficientes de testear el juego y asegurarse de que está bien nivelado. Mientras que los jugadores pueden acceder a mejores mazos tanto para conocer el juego, como para practicar y hasta competir.

2. Objetivos del proyecto


El objetivo global del proyecto es implementar un sistema de recomendación que, a partir de un mazo inicial entregado por el usuario, entregue un nuevo mazo con buen desempeño en las métricas que se propondrán. Lo anterior se traduce en los siguientes objetivos parciales:

1. Análisis de datos. (Logrado)
2. Implementar recomendaciones Random y Most Popular. (Logrado)
3. Implementar modelo propuesto en [Chen et al.2018]
4. Definir un tercer método para recomendar. (Logrado)
5. Implementar método Q-DecRec.
6. Establecer una comparación entre métodos en base al *win rate* de los mazos obtenidos con cada método.

3. Análisis descriptivo de los datos

En este apartado se presenta el análisis de los datos obtenidos de la plataforma HearthPwn (<https://www.hearthpwn.com/decks>). Esta base de datos contiene información detallada sobre los mazos creados por jugadores de Hearthstone. Los datos incluyen información sobre las clases de los mazos, las cartas utilizadas, el coste de creación, la puntuación de los mazos y otros metadatos relevantes.

En primer lugar, usamos estos datos para analizar la cantidad de mazos publicados según la clase del héroe para entender la popularidad relativa de cada una. De acá se obtuvo que las clases Mago, Sacerdote y Paladín son las con mayor cantidad de mazos publicados, siendo la clase Mago el con más mazos con un total de 45306. El resto de las clases cuentan con una cantidad muy similar de mazos publicados, aunque la clase Cazador tiene una leve caída en comparación al resto, con un total de 31245 mazos publicados.



Luego analizamos para cada clase, las cartas más usadas en sus mazos, obteniendo el porcentaje en el que estas cartas se presentan en los mazos, de forma que se pueda ver las cartas que pertenecen al meta del juego. En casi todas las clases se pueden encontrar una o dos cartas que sobresalen por mucho del resto, presentándose en más del 80% de sus mazos. Sobresalen mucho por ejemplo cartas como Fierly War Axe o Eviscerate para las clases Guerrero y Pícaro respectivamente, ambos apareciendo en el 90% de sus mazos aproximadamente.

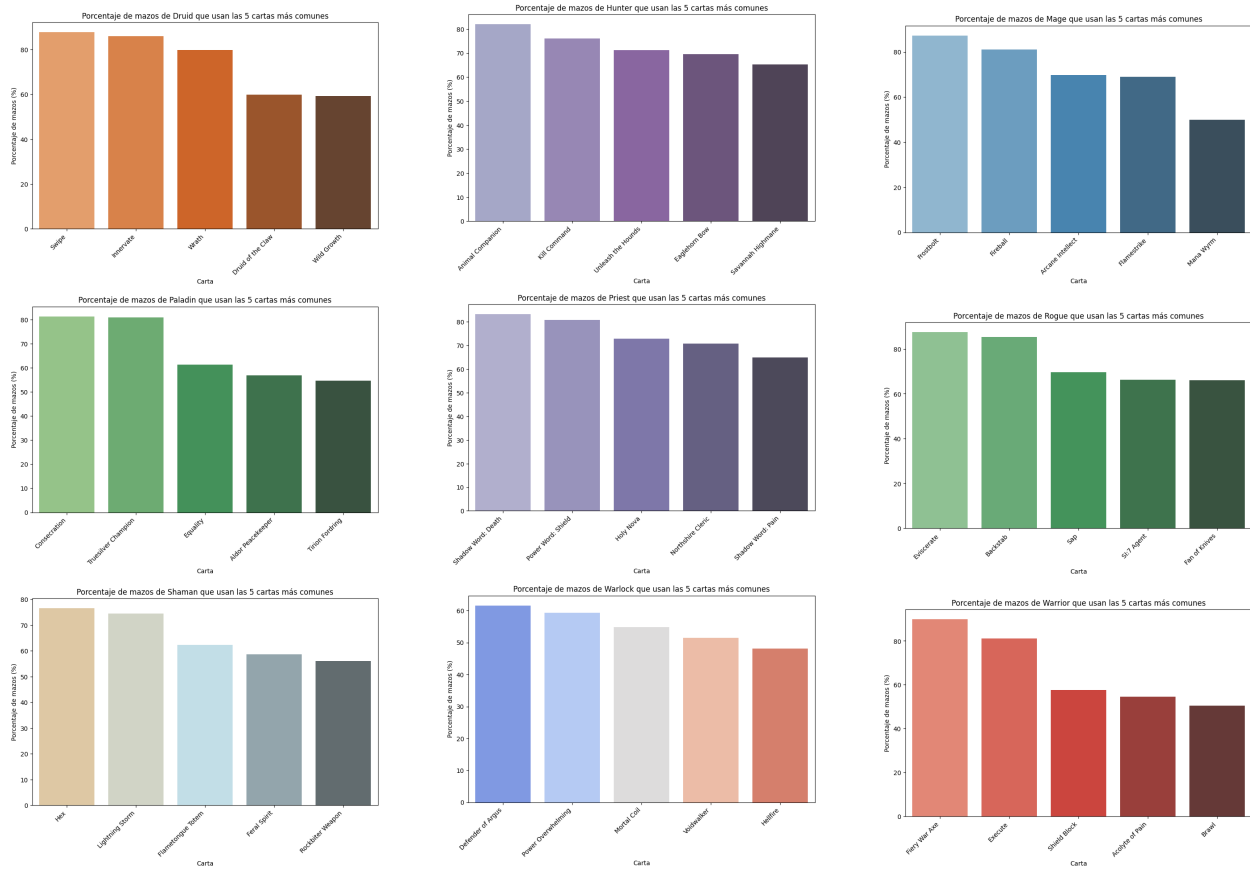


Figura 1: Porcentaje de mazos que usan las 5 cartas más comunes para cada clase de héroe

También es importante revisar si existen mazos con costes mucho más superiores que otras, así como saber si hay mazos que resulten ser por lo general “baratos”. Para esto se analizan los costes según los distintos arquetipos y por cada clase. Se puede observar como por lo general los mazos más caros son los con arquetipos “Reno” y “N’Zoth”, independiente de la clase. Además, para toda combinación Clase-Arquetipo, se presenta una mediana y un tercer cuartil con coste relativamente parecida entre los 5.000 y los 10.000.

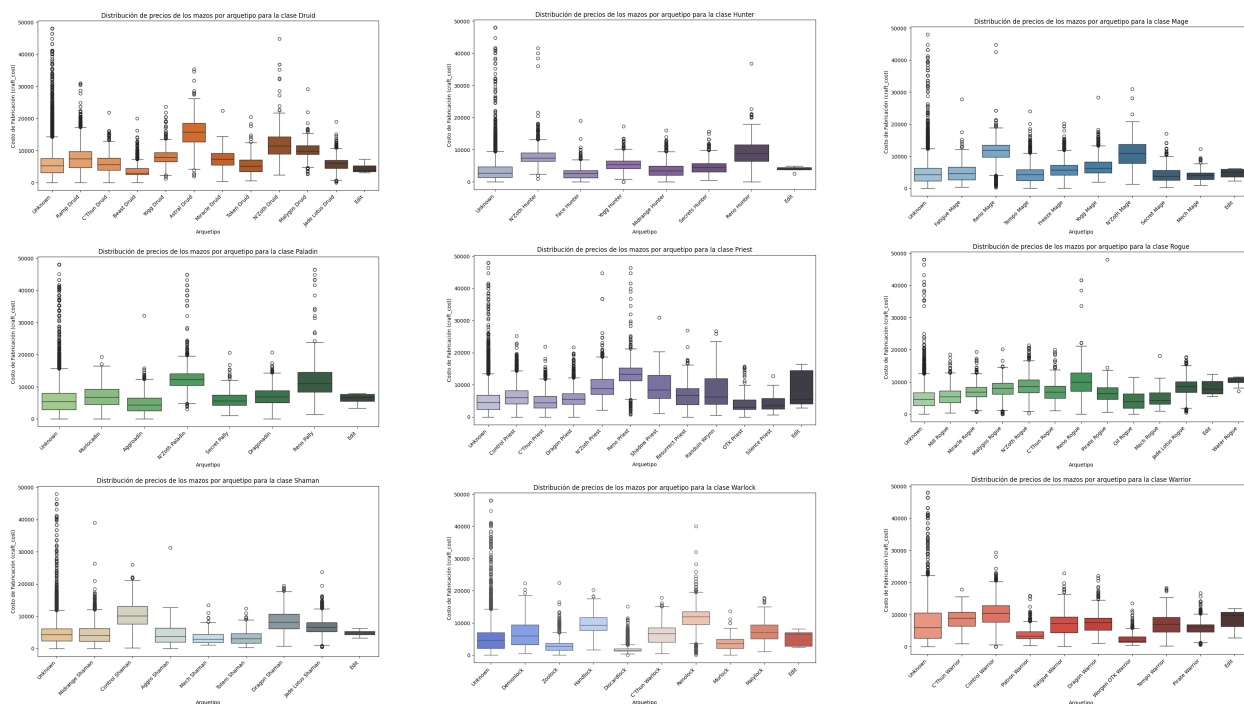




Figura 2: Distribución de precios de mazos por arquetipo para cada clase de héroe


En un cuarto lugar analizamos las puntuaciones promedio por cada clase. Para esto se comparó de tres maneras distintas. Primero se vieron los promedios de puntuaciones de forma normal, con lo que se obtuvo que las clases Guerrero y Cazador fueron las mejores puntuadas y la clase Paladín la peor.



En segundo se vieron con las puntuaciones normalizadas entre 0 y 1, con lo que se obtuvo un primer lugar muy claro de la clase Brujo y en segundo Cazador, además de una caída hasta el último lugar por mucho de la clase Guerrero.



En tercero se vieron las puntuaciones quitando los mazos con menos de 5 valoraciones, ya que parecieran ser muchísimos los mazos con bajas interacciones; de esto se obtuvo la clase Cazador se ponía en primer lugar, las demás con puntuaciones muy parecidas, y la clase Guerrero volvía a ocupar un lugar alto en la tercera posición.



De todo esto se puede notar cómo afecta mucho la alta cantidad de mazos con pocas interacciones en la base de datos, puesto que solo se pueden otorgar upvotes.

Finalmente, comprobamos la cantidad de mazos que se encuentran en estos rangos de bajas puntuaciones. Para esto separamos los mazos en tres rangos, aquellos con 1 o menos puntos, los que se encuentran entre 1 y 5, y finalmente todos aquellos que tienen puntuación por sobre 5. Para todas las clases, había una cantidad cercana a los 30.000 mazos en el rango bajo de puntuación, seguido de cerca de unos 5.000 mazos por clase con puntuación en el rango medio, dejando finalmente un porcentaje muy pequeño para la cantidad de mazos con relativamente muchas interacciones por parte de los usuarios de la plataforma en donde se obtuvo esta base de datos. Tampoco destaca demasiado alguna clase por sobre otra en términos de cantidad de mazos en el rango alto de las puntuaciones.

Todos los resultados mencionados pueden ser corroborados en los gráficos generados a través del análisis realizado por el equipo en el jupyter notebook con el código.

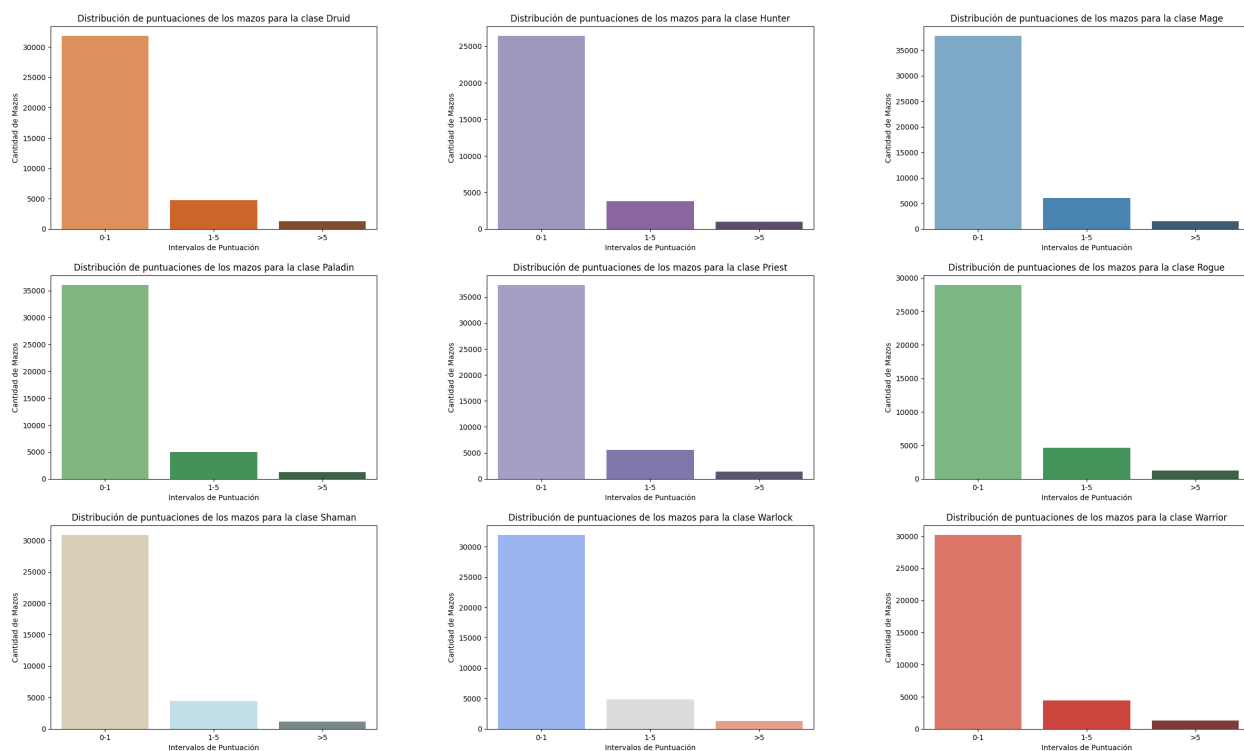


Figura 3: Distribución de puntuaciones de mazos para cada clase de héroe

4. Implementación de modelos de recomendación

El primer modelo de recomendación implementado es Random, este entrega de forma aleatoria un mazo de cartas. El segundo modelo, Most Popular, retorna el mazo con el mejor rating. Y por último se implementó un modelo llamado Best Similar que recibe un mazo y retorna un mazo similar con mejor rating. Para definir la similitud, se implementó una función que calcula la cantidad de cartas diferentes entre los mazos. De esta forma, el modelo también recibe como parámetro un delta que define la máxima posible diferencia entre el mazo retornado y el original.

5. Planificación del proyecto

1. Definir métricas (18 al 25 de Octubre)
2. Implementar método Q-DeckRec (14 al 23 de Octubre)
3. Comparar métodos (23 de Octubre al 4 de Noviembre)
4. Escribir informe (1 al 8 de Noviembre)

6. Estado del arte

En base a nuestra revisión bibliográfica pudimos ver que los sistemas recomendadores han sido vagamente explorados en este tipo de contexto y más aún si hablamos específicamente de Hearthstone.

De [Haumann and Höppner2024] y [Hoover et al.2020] podemos ver que las propuestas que alcanzan mejor desempeño tanto en este contexto como en juegos similares como “Magic the gathering” tienden a centrarse en un uso importante de mecanismo de machine learning, lo cual es natural debido al nivel de combinaciones y posibilidades intrínsecas de cada juego. Más aún, el escalamiento de estos sistemas suele ser bastante deficiente tal como es mencionado por [Chen et al.2018].

Finalmente, tenemos que heartstone es un juego que con una comunidad que presenta considerable interés por las estadísticas del juego tal como dejan en claro la existencia de “<https://www.hearthpwn.com/>”, sitio del cual obtuvimos nuestra base de datos, y estudios como el de [Mora et al.2022], enfocados en la recopilación y análisis de datos para futuros proyectos de recomendación.

Referencias

- [Chen et al.2018] Chen, Z., Amato, C., Nguyen, T.-H. D., Cooper, S., Sun, Y., and El-Nasr, M. S. (2018). Q-deckrec: A fast deck recommendation system for collectible card games. page 1–8.
- [Haumann and Höppner2024] Haumann, T. and Höppner, F. (2024). Adaptivity of card recommendation systems for legends of code and magic. pages 1–8.
- [Hoover et al.2020] Hoover, A. K., Togelius, J., Lee, S., and de Mesentier Silva, F. (2020). The many ai challenges of hearthstone. *KI-Künstliche Intelligenz*, 34:33–43.
- [Mora et al.2022] Mora, A. M., Tonda, A., Fernández-Ares, A. J., and García-Sánchez, P. (2022). Looking for archetypes: Applying game data mining to hearthstone decks. *Entertainment Computing*, 43:100498.